# 王鑫

旧金山，加利福尼亚州 john.doe@email.com rendercv.com rendercv rendercv

## 教育背景

博士 普林斯顿大学, 计算机科学 — 普林斯顿，新泽西州 — 9 月 2018 – 5 月 2023
- 博士论文：面向资源受限部署的高效神经架构搜索
- 导师：Sanjeev Arora 教授
- NSF 研究生奖学金、Siebel 学者（2022 届）

学士 波斯普鲁斯大学, 计算机工程 — 伊斯坦布尔，土耳其 — 9 月 2014 – 6 月 2018
- GPA: 3.97/4.00，毕业生代表
- 富布赖特奖学金获得者

## 工作经历

**Nexus AI**, 联合创始人兼首席技术官 — 旧金山，加利福尼亚州 — 6 月 2023 – 至今
- 构建基础模型基础设施，月均处理超过 200 万次 API 请求，正常运行时间达 99.97%
- 完成 1800 万美元 A 轮融资，由红杉资本领投，a16z 和 Founders Fund 跟投
- 将工程团队从 3 人扩展至 28 人，涵盖机器学习研究、平台和应用 AI 三个方向
- 开发专有推理优化方案，相比基准延迟降低 73%

**NVIDIA** 研究院, 研究实习生 — 圣克拉拉，加利福尼亚州 — 5 月 2022 – 8 月 2022
- 设计稀疏注意力机制，将 Transformer 内存占用降低至原来的 1/4.2
- 合著论文被 NeurIPS 2022 接收（亮点报告，投稿前 5%）

**Google DeepMind**, 研究实习生 — 伦敦，英国 — 5 月 2021 – 8 月 2021
- 开发多智能体协作的强化学习算法
- 在顶级学术会议发表重要影响力的研究成果
- ICML 2022 主会议论文，两年内被引用 340+ 次
- NeurIPS 2022 研讨会论文，关于涌现通信协议
- JMLR (2023) 邀请扩展论文

**Apple** 机器学习研究院, 研究实习生 — 库比蒂诺，加利福尼亚州 — 5 月 2020 – 8 月 2020
- 创建端侧神经网络压缩流水线，部署于超过 5000 万台设备
- 申请 2 项关于高效模型量化技术的专利

微软研究院, 研究实习生 — 雷德蒙德，华盛顿州 — 5 月 2019 – 8 月 2019
- 实现面向低资源语言建模的新型自监督学习框架
- 研究成果集成至 Azure 认知服务，训练数据需求减少 60%

## 项目经历

**FlashInfer** — 1 月 2023 – 至今

高性能大语言模型推理内核开源库
- 在 A100 GPU 上实现相比基准注意力实现 2.8 倍加速
- 被 3 个主要 AI 实验室采用，GitHub 8,500+ Stars，200+ 贡献者

**NeuralPrune** 1 月 2021

基于可微分掩码的自动化神经网络剪枝工具包

- 在 ImageNet 上将模型大小缩减 90%，精度损失低于 1%
- 入选 PyTorch 生态工具，GitHub 4,200+ Stars

## 学术发表

大规模稀疏混合专家模型：面向万亿参数模型的高效路由 7 月 2023
王鑫, Sarah Williams, David Park
10.1234/neurips.2023.1234 (NeurIPS 2023)

基于可微分剪枝的神经架构搜索 12 月 2022
James Liu, 王鑫
10.1234/neurips.2022.5678 (NeurIPS 2022, 亮点报告)

基于涌现通信的多智能体强化学习 7 月 2022
Maria Garcia, 王鑫, Tom Anderson
10.1234/icml.2022.9012 (ICML 2022)

基于学习量化的端侧模型压缩 5 月 2021
王鑫, Kevin Wu
10.1234/iclr.2021.3456 (ICLR 2021, 最佳论文奖)

## 荣誉奖项

- MIT Technology Review 35 位 35 岁以下创新者（2024）
- Forbes 30 Under 30 企业科技领域（2024）
- ACM 博士论文奖荣誉提名（2023）
- Google 机器学习博士奖学金（2020 – 2023）
- 富布赖特研究生奖学金（2018）

## 专业技能

**编程语言:** Python, C++, CUDA, Rust, Julia

**机器学习框架:** PyTorch, JAX, TensorFlow, Triton, ONNX

**基础设施:** Kubernetes, Ray, 分布式训练, AWS, GCP

**研究方向:** 神经架构搜索、模型压缩、高效推理、多智能体强化学习

## 专利

1. 神经网络端侧推理的自适应量化方法（美国专利 11,234,567）
2. 高效 Transformer 注意力的动态稀疏模式（美国专利 11,345,678）
3. 硬件感知的神经架构搜索方法（美国专利 11,456,789）

## 受邀报告

4. 高效推理的缩放定律 — 斯坦福 HAI 研讨会（2024）
3. 构建下一代 AI 基础设施 — TechCrunch Disrupt（2024）
2. 从研究到生产：机器学习系统的经验教训 — NeurIPS 研讨会（2023）
1. 高效深度学习：实践者的视角 — Google 技术讲座（2022）